
Proyecto Centinela — Fase 2: CNN + LSTM/GRU y Fusión Multimodal

Sistema de alerta temprana del poder adquisitivo del SMLV

Estefanny Ruíz González^a
estefannyruiz@usantotomas.edu.co

Miguel Alarcón Ojeda^b
miguel.alarcon@usantotomas.edu.co

1. Problema, contexto y arco del proyecto

El Proyecto Centinela busca construir un sistema de alerta temprana que prediga si el poder adquisitivo del salario mínimo legal vigente (SMLV) en Colombia está en riesgo de deteriorarse. La Fase 1 estableció la línea base con un perceptrón multicapa (MLP) sobre datos económicos mensuales de Bogotá, obteniendo un *recall* de 0.846 y F1 de 0.880 sobre la clase de riesgo.

La Fase 2 extiende el sistema incorporando **dos modalidades de datos**:

- **Rama B (serie temporal)**: TRM diaria procesada con RNN simple, LSTM y GRU.
- **Rama A (imágenes)**: matrices de recurrencia generadas desde la serie TRM, comparando ResNet18 y EfficientNet-B0 con Transfer Learning.
- **Rama C (fusión)**: concatenación tardía GRU + CNN con estudio de ablación.

Dado que el proyecto no cuenta con imágenes naturales, se implementó el **Plan B** de forma autónoma: matrices de recurrencia como representación visual de la serie temporal, notificado al docente.

2. Rama B: serie temporal con LSTM, GRU y RNN

2.1. Datos y justificación de la fuente

La TRM es el precio oficial del dólar en Colombia, certificado diariamente por la Superintendencia Financiera (Superintendencia Financiera de Colombia, 2026). El archivo fue descargado el 7 de julio de 2026 desde Datos Abiertos Colombia.

2.2. Preprocesamiento

Variable objetivo: retorno porcentual diario. $r_t = (TRM_t - TRM_{t-1}) / TRM_{t-1} \times 100$. Los retornos son estacionarios (media $\approx 0.012\%$, std $\approx 0.73\%$) y resuelven la extrapolación severa que causaba el nivel absoluto (Goodfellow et al., 2016).

^aEstudiante

^bEstudiante

Partición y escalado. Cronológica 70/15/15; ventana de 30 días; 6.277 ejemplos. MinMaxScaler ajustado solo en train.

2.3. Arquitecturas implementadas

Arquitectura	Parámetros	Puertas	Rol
RNN simple	12.673	0	Referencia / evidencia desvanecimiento
LSTM	50.497	3 (olvido, entrada, salida)	Memoria larga
GRU	37.889	2 (reinicio, actualización)	Eficiente

Tabla 1: Arquitecturas recurrentes implementadas (Hochreiter y Schmidhuber, 1997; Cho et al., 2014).

2.4. Resultados




Figura 1: Curvas de pérdida (train vs. validación). LSTM y GRU convergen más suavemente que la RNN simple.

Modelo	RMSE (%)	MAE (%)	Época early stop
RNN	0.8342	0.6416	19
LSTM	0.8349	0.6453	50
GRU	0.8343	0.6435	60

Tabla 2: Métricas en test. MAPE $\approx 103\%$ por limitación matemática cuando el retorno real es ≈ 0 ; RMSE y MAE son las métricas relevantes.

Las predicciones tienden a cero, lo que ilustra la hipótesis del mercado eficiente: en mercados cambiarios líquidos, los retornos pasados contienen poca información sobre los futuros (Goodfellow et al., 2016).

2.5. Evidencia del desvanecimiento del gradiente

3. Rama A: imágenes con CNN y Transfer Learning

3.1. Datos: matrices de recurrencia

Al no contar con imágenes naturales, se generaron **matrices de recurrencia** desde la TRM diaria. Cada ventana de 30 días genera una imagen de 30×30 píxeles: el píxel (i, j) vale 1 si $|r_i - r_j| < 0.5\%$, y 0 en caso contrario.




Figura 2: Norma del gradiente de la capa 0. La RNN colapsa a 0.0009 mientras el LSTM mantiene 0.003 ($\approx 3.5\times$ mayor). Las puertas del LSTM permiten que la señal de error fluya hacia atrás (Hochreiter y Schmidhuber, 1997).

Data augmentation (solo en train): rotación aleatoria $\pm 15^\circ$, flip horizontal y variación de brillo $\pm 20\%$. Estas transformaciones aumentan la robustez del modelo sin alterar la estructura temporal de los patrones.

Las 6.277 ventanas se etiquetan por retorno acumulado: Clase 0 (Depreciación, $> +1\%$): 2.517 (40.1%); Clase 1 (Estable, $\pm 1\%$): 1.360 (21.7%); Clase 2 (Apreciación, $< -1\%$): 2.400 (38.2%).

3.2. Selección de arquitectura: ResNet18 vs. EfficientNet-B0

Arquitectura	Parámetros	Profundidad	Top-1 ImageNet	Estrategia
ResNet18	11.2 M	18 capas	69.8 %	Feature Extraction
EfficientNet-B0	5.3 M	82 capas	77.1 %	Feature Extraction

Tabla 3: Comparación de arquitecturas preentrenadas. Feature Extraction es apropiada porque el dominio (matrices binarias) difiere significativamente de ImageNet (He et al., 2016; Tan y Le, 2019).

Justificación Feature Extraction vs Fine-Tuning: Con 6.277 imágenes en un dominio muy distinto a ImageNet, el Fine-Tuning profundo arriesga sobreajustar y destruir representaciones preentrenadas útiles. Feature Extraction congela las capas convolucionales y solo reentrena la capa final ($< 2\%$ de los parámetros).

3.3. Resultados comparativos

Arquitectura	Accuracy	F1 macro	Parámetros
ResNet18	0.496	0.342	11.2 M
EfficientNet-B0	0.497	0.343	5.3 M

Tabla 4: Tabla comparativa — test ($n = 942$). EfficientNet-B0 obtiene marginalmente mejor desempeño con menos de la mitad de los parámetros.

Arquitectura seleccionada: EfficientNet-B0. Aunque las diferencias son marginales (Acc: 0.497 vs




Figura 3: Curvas de pérdida — ResNet18 vs EfficientNet-B0. EfficientNet-B0 muestra validación más estable; ResNet18 tiene más oscilaciones en val.




Figura 4: Matrices de confusión comparativas. Ambas arquitecturas predicen Depreciación mayoritariamente (clase dominante).

0.496; F1: 0.343 vs 0.342), EfficientNet-B0 logra un desempeño ligeramente superior con 5.3 M parámetros frente a 11.2 M de ResNet18, lo que lo hace más eficiente para despliegue futuro (Tan y Le, 2019).

3.4. Grad-CAM — interpretabilidad

Limitación honesta: las representaciones de ImageNet no son óptimas para matrices de recurrencia binarias. Fine-Tuning profundo o una CNN entrenada desde cero podrían mejorar los resultados.

4. Rama C: fusión multimodal y estudio de ablación

4.1. Arquitectura de fusión

Concatenación tardía (Baltrušaitis et al., 2019): GRU (embedding 64 dims) + EfficientNet-B0 (embedding 512 dims) $\rightarrow$ Linear(576 $\rightarrow$ 128) $\rightarrow$ ReLU $\rightarrow$ Dropout(0.3) $\rightarrow$ Linear(128 $\rightarrow$ 3). Clave de alineación:




Figura 5: Grad-CAM — ResNet18 (Selvaraju et al., 2017). Depreciación activa la zona central-superior; Apreciación activa la inferior-izquierda. El modelo detecta patrones de dirección, no activa al azar.

misma ventana de 30 días para ambas ramas.

4.2. Estudio de ablación




Figura 6: Curvas de pérdida — estudio de ablación. GRU y Fusión sobreajustan severamente (val loss > 8). CNN mantiene val ≈ 1.1 .

Análisis: la CNN sola supera al GRU y a la fusión. El GRU sobreajustó en clasificación porque fue optimizado para regresión de retornos (Rama B), no para clasificar 3 categorías. La fusión hereda ese

Modelo	Accuracy	F1 macro
Solo GRU	0.364	0.297
Solo CNN	0.470	0.341
Fusión	0.343	0.325


Tabla 5: Estudio de ablación — test ($n = 942$).

Figura 7: Matrices de confusión — estudio de ablación (test).

problema. **Principio general:** la fusión multimodal solo mejora cuando cada modalidad aporta embeddings de calidad (Baltrušaitis et al., 2019). Un resultado negativo bien analizado tiene más valor que una mejora artificial.

5. Visualizaciones para el cliente

Las siguientes visualizaciones están diseñadas para un analista de política pública o de un gremio laboral que no tiene formación técnica en *deep learning*.

Comportamiento histórico (2000–2026): la TRM coloreada por régimen detectado permite identificar periodos de depreciación sostenida (señal de alerta) vs. estabilidad o apreciación, con hitos históricos anotados.

Distribución anual: cuántos días hábiles por año estuvo el peso en cada régimen, facilitando la comparación de años de mayor vs. menor presión cambiaria.

Alerta actual (últimos 90 días): panel de monitoreo con el estado reciente del sistema. Un régimen de Depreciación sostenida indica presión sobre el poder adquisitivo del SMLV y puede anticipar la necesidad de ajustes de política salarial.

6. Análisis ético

La TRM es una variable **intermedia**: su subida presiona bienes importados y puede erosionar el salario real, pero la relación no es inmediata ni uniforme para todos los hogares. El sistema de la Rama B debe interpretarse como una señal de alerta de presión cambiaria, no como una predicción directa de caída del poder adquisitivo.

Se mantiene el anclaje al **Marco Ético para la Inteligencia Artificial en Colombia** (Minciencias, 2021), que antepone el impacto real sobre las personas a la exactitud agregada. El sistema se concibe

como apoyo a la decisión experta, no como su sustituto.

7. Limitaciones y trabajo futuro

- **Eficiencia del mercado.** Los retornos de la TRM son difíciles de predecir en mercados líquidos.
- **Representaciones CNN.** Las capas convolucionales de ImageNet no son óptimas para matrices de recurrencia binarias.
- **Embedding del GRU.** Sobreajusta en clasificación; requerida mayor regularización o reentrenamiento específico para esta tarea.
- **Trabajo futuro (asesora del proyecto):** índice de asequibilidad (canasta familiar / SMLV) y agrupamiento jerárquico por *Dynamic Time Warping* (DTW) para clústeres de ciudades.
- **Generalización.** Una sola ciudad piloto (Bogotá).

Referencias

- Baltrušaitis, T., Ahuja, C., & Morency, L.-P. (2019). Multimodal machine learning: A survey and taxonomy. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 41(2), 423–443. <https://doi.org/10.1109/TPAMI.2018.2798607>
- Cho, K., van Merriënboer, B., Gulcehre, C., Bahdanau, D., Bougares, F., Schwenk, H., & Bengio, Y. (2014). Learning phrase representations using RNN encoder-decoder for statistical machine translation. *arXiv:1406.1078*. <https://arxiv.org/abs/1406.1078>
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning* (Caps. 9 y 10). MIT Press. <https://www.deeplearningbook.org/>
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. En *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* (pp. 770–778). <https://doi.org/10.1109/CVPR.2016.90>
- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735>
- Ministerio de Ciencia, Tecnología e Innovación (Minciencias). (2021). *Marco ético para la inteligencia artificial en Colombia*. Gobierno de Colombia.
- Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., & Batra, D. (2017). Grad-CAM: Visual explanations from deep networks via gradient-based localization. En *Proceedings of the IEEE International Conference on Computer Vision (ICCV)* (pp. 618–626). <https://doi.org/10.1109/ICCV.2017.74>
- Superintendencia Financiera de Colombia. (2026). *Tasa de cambio representativa del mercado (TRM) — serie histórica diaria* [Conjunto de datos]. Datos Abiertos Colombia. <https://datos.gov.co/Economia-y-Finanzas/TRM/ceyp-9c7c>
- Tan, M., & Le, Q. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. En *Proceedings of the 36th International Conference on Machine Learning (ICML)* (pp. 6105–6114). <https://arxiv.org/abs/1905.11946>